前期工作与论文阅读总结.md 2019/4/24

论文阅读与前期工作总结

姓名:张昊,张浩轩,严萌,秦晨曦

学号:17343148,17343149,17343134,17343096

前期工作

使用示意图展示普通文件IO方式(fwrite等)的流程,即进程与系统内核,磁盘之间的数据交换如何进行?为什么写入完成后要调用fsync?

```
application buffer

| clib buffer
| page cache
| Io queue
| drive
| disk cache
| disk
```

- 1. 应用程序先将内容写入应用程序的application buffer
- 2. 调用fwrite将内容写入CLib buffer
- 3. 然后此时flush函数把数据从CLib buffer 拷贝到page cache中
- 4. 从page cache刷新到磁盘上可以通过调用fsync函数 最后调用fsync函数是为了将文件从内存同步到硬盘,如果不调用的话,程序意外崩溃,数据就会发生丢失。

简述文件映射的方式如何操作文件。与普通IO区别?为什么写入完成后要调用msync?文件内容什么时候被载入内存?

- 1. Linux提供了内存映射函数mmap, 它把文件内容映射到一段内存上(准确说是虚拟内存上), 通过对这段内存的读取和修改, 实现对文件的读取和修改
 - 1. 进程启动映射过程,并在虚拟地址空间中为映射创建虚拟映射区域
 - 2. 调用内核空间的系统调用函数mmap(不同于用户空间函数),实现文件物理地址和进程虚拟地址的——映射关系
 - 3. 进程发起对这片映射空间的访问,引发缺页异常,实现文件内容到物理内存(主存)的拷贝
- 2. 与普通io的区别
 - 1. 文件映射没有频繁的数据拷贝,只有发生缺页时才会有数据拷贝,由于mmap()将文件直接映射到用户空间,所以中断处理函数根据这个映射关系,直接将文件从硬盘拷贝到用户空间,只进行了一次数据拷贝
 - 2. 常规文件操作需要从磁盘到页缓存再到用户主存的两次数据拷贝

前期工作与论文阅读总结.md 2019/4/24

- 3. 因为此时数据还保留在内存上,掉电之后数据丢失,因此需要保存在硬盘上
- 4. 调用msync()函数(显示同步)时和结束时调用munmap()后自动调用msync()函数进行同步

参考Intel的NVM模拟教程模拟NVM环境,用fio等工具测试模拟NVM的性能并与磁盘对比(关键步骤结果截图)。

首先建立nvm环境,然后是将nvm挂载到了/home/ubuntu/pmemdir目录下

```
      ubuntu@ubuntu-TM1604:~$ sudo mkfs.ext4 /dev/pmem0

      mke2fs 1.44.1 (24-Mar-2018)

      创建含有 262144 个块(每块 4k)和 65536 个inode的文件系统

      文件系统UVID: 9f733c4a-c644-4e3a-87f0-1029430b1516

      超级块的备份存储于下列块:

      32768, 98304, 163840, 229376

      正在分配组表: 完成

      正在写入inode表: 完成

      创建日志 (8192 个块) 完成

      写入超级块和文件系统账户统计信息: 已完成

      ubuntu@ubuntu-TM1604:~$ sudo mount -o dax /dev/pmem0 /home/ubuntu/pmemdir/
```

然后安装fio,在ubuntu下的命令是:

```
apt-get install fio
```

首先我们测试nvm盘的速度,这里是指令

```
sudo fio -filename=/home/ubuntu/pmemdir -direct=1 -iodepth 1 -thread -
rw=randrw -ioengine=psync -bs=16k -size=200M -numjobs=10 -runtime=1000 -
group_reporting -name=fiotest
```

这里比较重要的参数是rw=randrw读写都是随即读写和-size=200M测试文件大小是200M.首先运行在nvm环境下,做了三组测试:

随机读

前期工作与论文阅读总结.md 2019/4/24

• 随机写

混合随机读写

然后我们测试自己的硬盘,由于我电脑是SSD,所以速度较快.

前期工作与论文阅读总结.md 2019/4/24

随机读

• 随机写

混合随机读写

```
### Total Control | This Control Contr
```

前期工作与论文阅读总结.md 2019/4/24

```
submit : 0=0.0%, 4=100.0%, 8=0.0%, 16=0.0%, 32=0.0%, 64=0.0%, >=64=0.0%
complete : 0=0.0%, 4=100.0%, 8=0.0%, 16=0.0%, 32=0.0%, 64=0.0%, >=64=0.0%
issued rwt: total=63811,64189,0, short=0,0,0, dropped=0,0,0
latency : target=0, window=0, percentile=100.00%, depth=1

Run status group 0 (all jobs):
    READ: bw=53.4MiB/s (55.0MB/s), 53.4MiB/s-53.4MiB/s (55.0MB/s-55.0MB/s), io=997MiB (1045MB), run=18670-18670msec
WRITE: bw=53.7MiB/s (56.3MB/s), 53.7MiB/s-53.7MiB/s (56.3MB/s-56.3MB/s), io=1003MiB (1052MB), run=18670-18670msec

Disk stats (read/write):
    sda: ios=63770/64170, merge=0/20, ticks=520/0, in_queue=28820, util=88.79%
```

使用PMDK的libpmem库编写样例程序操作模拟NVM(关键实验结果截图,附上编译命令和简单样例程序)。

安装PMDK的步骤很简单,基本就是如下几步:

```
git clone https://github.com/pmem/pmdk.git
cd pmdk
make
sudo make install
```

make install 会把.so文件安装到/usr/lib的系统目录下,会把头文件安装到/use/local/include下,如果不加sudo权限不够下面是**编译样例** 这里我们编译的是

```
pmdk/src/examples/libpmem/full_copy.c,使用如下命令
ubuntu@ubuntu-TM1604:~/DBMS$ gcc full_copy.c -o full_copy-pthread -lpmem
ubuntu@ubuntu-TM1604:~/DBMS$ ls
DataBase full_copy.c full_copy-pthread homework pmdk
```

这里需要链接两个动态链接库,分别是多线程的动态链接库和 libpmem.so文件,然后我们测试一下

```
ubuntu@ubuntu-TM1604:~/DBMS$ sudo ./full_copy-pthread full_copy-pthread /mnt/pme
mdir/full
ubuntu@ubuntu-TM1604:~/DBMS$ ls /mnt/pmemdir/
full
```

论文阅读

总结一下本文的主要贡献和观点(500字以内)(不能翻译摘要)。

首先背景是随着科技的发展,出现了许多新型内存技术,不同于闪存,SCM它具有非易失性的特性,具备超越闪存的潜力。然而对于SCM,写操作会慢于读操作,所以之前主要以闪存为基础而设计的b-树会不再适用于SCM,因此需要重新设计一种树来利用SCM的功能。在此之前已经有了CDDS b树 ,wBTree,NV-Tree,bsigut,但在内存泄漏和数据恢复等方面表现得不尽如人意。而本文中所提出的 FBTree却是利用SCM来实现良好的数据结构性能。

FBTree的设计原则有四条:

- 利用指纹识别,降低搜索时间,提高性能。
- 利用在SCM中存储主数据,在DRAM中存储非主数据,降低在访问数据时所需要的时间,同时这也导致了FBTree能够快速的恢复。
- 通过对不同状态选择不同的并发方案来达到有选择并发性,通过选择性的执行工作,防止HTM在并发时执行其他的操作。

前期工作与论文阅读总结.md 2019/4/24

• 良好的编程模型。其中数据的回复和内存泄漏问题任然没有很好的得到解决。

通过测验,FBTree的内存使用更少,数据恢复时间更快,性能开销更小,同时FBTree对于SCM的高延迟具有较好的弹性,在数据恢复方面也保证了不会丢失信息。

SCM硬件有什么特性?与普通磁盘有什么区别?普通数据库以页的粒度读写磁盘的方式适合操作SCM吗?

SCM硬件有什么特性?

- SCM(Storage Class Memory) 存储类内存, 也叫做**persistent memory,** 它最大的特点就是 **persistent**, 也就是非易失性, 通俗来讲就是断电后原有的数据还在, 并不会像RAM一样丢失.
- 另外SCM还有容量大的特性, 一般而言, SCM的容量可以达到1TB甚至更高, 并且价格合理, 能够让大部分 人负担得起.
- SCM具有快速读取的特性,读取速度仅仅与DRAM相当,写入速度较DRAM而言则相差10到100倍以上.
- 论文中的话是

SCM combines the economic characteristics, capacity, and non-volatility property of traditional storage media with the low latency and byte-addressability of DRAM.

SCM has a potential that goes beyond replacing DRAM: it can be used as universal memory, that is, as main memory and storage at the same time.

SCM与普通磁盘有什么区别?普通数据库以页的粒度读写磁盘的方式适合操作SCM吗?

- 读写不对称, 在SCM上, 读取的速度是明显大于写入的速度.
- SCM的读写速度虽然比不上DRAM, 但是比磁盘速度快, 一般来讲, SCM的速度介于DRAM与SSD之间.
- SCM具有作为NVM设备的致命缺陷, 也就是说写入的次数有限, 写入几百万次时可能会造成永久失效的问题. 而磁盘不同, 就HDD来讲, 寿命非常长, 一般可以使用10年以上, 就SSD来讲, 一般可以写入1万次到10万次以上, 寿命比HDD短一些, 但是这里的写入是指一个颗粒的写入次数, 而不是磁盘整体的写入次数, 所以SSD的寿命还是可以接受的. 在这一点上SCM与HDD的区别较大, 与SSD有相似点.
- 低能耗,与磁盘相比,无论是读取还是写入,SCM的能耗更低.

结合上述特点,特别是写入次数而言,SCM的写入次数非常expensive,而且论文中也多次提到

Chen et al. proposed to use unsorted nodes with bitmaps to decrease the number of **expensive** writes to SCM.

Leaf nodes however keep keys unsorted and use a bitmap to track valid entries in order to reduce the number of **expensive SCM writes.**

所以我们秉持的宗旨之一就是尽量减少对SCM的写入次数,而且由于SCM是按字节寻址的,如果和普通数据库读写磁盘一样以页的方式,那么就会产生不必要的读写次数,从而减少了SCM的寿命.因此我们应该把计算操作与持久存储操作分离,只存储必要的数据,使得对SCM的写入尽量减少,延长使用寿命.

操作SCM为什么要调用CLFLUSH等指令?

前期工作与论文阅读总结.md 2019/4/24

• 由于SCM的存储,访问是一个长链,需要很多的硬件,它的写操作是必须要软件协作的.CLFLUSH指令在处理器缓存层次结构(数据与指令)的所有级别中,使包含源操作数指定的线性地址的缓存线失效。失效会在整个缓存一致性域中传播。如果缓存层次结构中任何级别的缓存线与内存不一致(污损),则在使之失效之前将它写入内存。而FENCE 指令,也称内存屏障(Memory Barrier),起着约束其前后访存指令之间相对顺序的作用。

• 我们使用CLFLUSH等命令来将那些高速缓存中的写变成持久性的,并且由于他们并不删除cache line中的内容,仅是将其中内容写回,这将极大的提高cache line再次使用时的效率,论文中也提到:

Contrary to CLFLUSH, CLWB does not evict the cache line but simply writes it back, which can lead to significant performance gains when the cache line is re-used shortly after it was written back.

写入后不调用,发生系统崩溃有什么后果?

如果没有调用这些函数,系统便发生崩溃,那么将造成数据的

FPTree的指纹技术有什么重要作用?

在SCM中,对于未排序的叶子节点,采用线性扫描需要花费大量时间,使用指纹技术, 可以提前过滤掉不合适的值,从而提高FBTree的检索效率。

指纹技术在原文中是这么定义的

To enable better performance, we propose a technique called Fingerprinting. Fingerprints are one-byte hashes of leaf keys, stored contiguously at the beginning of the leaf as illustrated in Figure 2. By scanning them first during a search, fingerprints act as a filter to avoid probing keys that have a fingerprint that does not match that of the search key.

在我的理解中就是用一个哈希表保存FBTree中的数据的个数,该表放在FBtree的首端 ,在检测数据时,先在该表中进行过滤,即可提高检索效率。

为了保证指纹技术的数学证明成立,哈希函数应如何选取?

(哈希函数生成的哈希值具有什么特征,能简单对键值取模生成吗?)

Fingerprints are one-byte hashes of leaf keys, stored contiguously at the beginning of the leaf as illustrated in Figure 2. By scanning them first during a search, fingerprints act as a filter to avoid probing keys that have a fingerprint that does not match that of the search key.

We assume a hash function that generates uniformly distributed fingerprints.

也就是说哈希函数要生成一个均匀分布的fingerprints, 而简单地对键值取模生成的哈希值很明显不是均匀分布的, 所以哈希函数不能对键值取模生成.

持久化指针的作用是什么?与课上学到的什么类似?

- 持久化指针和持久化分配器配合来保证数据的一致性.由于FPTree中的叶子节点与内节点分别存储在 SCM与DRAM中,所以在重启应用时的数据恢复和使用需要持久化指针的帮助.
- 持久化指针包含8byte的文件ID,以及8byte的偏移量.文件ID对应的文件是由持久化分配器分配的.而虚拟 指针也通过持久化分配器来进行虚拟指针和吃计划指针的相互转换.持久化指针在程序崩溃或者其他异常

的时候仍然是有效的,可以用来在重启时更新虚拟指针,使得程序的重启顺利进行.